
UNIVERSITÉ HASSAN 1^{er}
ÉCOLE NATIONALE DE COMMERCE ET DE GESTION
DE SETTAT

COMPTE RENDU DE PROJET

Classification des Défaillances de Contrôle Interne par Type

Intitulé :	Classification des défaillances de contrôle interne par type
Module :	Intelligence Artificielle Appliquée
Filière :	Contrôle, Audit et Conseil — L3 S7
Réalisé par :	Rajib Hidaya & Ezzaher Douaa
Encadrant :	—
Année universitaire :	2024–2025

SOMMAIRE

I. Introduction	3
II. Problématique et type de tâche	3
III. Dictionnaire des variables	4
IV. Méthodologie	4
IV.1 Pré-traitement	4
IV.2 Algorithmes testés	5
IV.3 Validation et optimisation	5
V. Résultats	5
V.1 Analyse exploratoire (EDA)	5
V.2 Performances des modèles	7
VI. Conclusion	9

I. Introduction

Le présent compte rendu porte sur la conception et l'évaluation d'un modèle de machine learning destiné à classifier automatiquement les défaillances de contrôle interne dans le cadre du référentiel **SOX (Sarbanes-Oxley Act)**. Chaque observation correspond à un rapport d'audit et contient des informations sur le profil de l'entreprise (taille, secteur, domaine de contrôle) ainsi que des indicateurs quantitatifs de risque et de défaillance.

L'objectif est d'utiliser ces informations pour prédire automatiquement le **type de défaillance de contrôle interne** identifiée lors d'un audit, contribuant ainsi à l'optimisation des processus de gouvernance et à la priorisation des risques par les équipes d'audit.

II. Problématique et type de tâche

La question centrale de ce projet est la suivante : *peut-on classifier automatiquement le type de défaillance de contrôle interne à partir des caractéristiques d'un rapport d'audit SOX ?*

Il s'agit d'une **classification multiclasse supervisée**. La variable cible peut prendre cinq valeurs distinctes, correspondant aux niveaux de sévérité définis par le PCAOB :

Classe	Description
Material Weakness	Défaillance grave susceptible d'affecter les états financiers
Significant Deficiency	Déficiences importantes mais moins critiques
Control Deficiency	Déficiences mineures, portée limitée
Compliance Violation	Non-respect d'une disposition réglementaire
Fraud Risk	Présence d'indicateurs de risque de fraude

III. Dictionnaire des variables

Le dataset synthétique utilisé comporte 2 000 observations et 8 variables, dont une variable cible. Le tableau ci-dessous présente l'ensemble des variables retenues :

Variable	Type	Description
company_size	Catégorielle	Taille de l'entreprise (Small / Medium / Large)
industry_sector	Catégorielle	Secteur d'activité

control_area	Catégorielle	Domaine de contrôle concerné
num_findings	Numérique	Nombre de constats identifiés
remediation_days	Numérique	Jours nécessaires pour la remédiation
risk_score	Numérique	Score de risque global (0–100)
prior_deficiency	Binaire	Défaillance lors de la période précédente (0/1)
deficiency_type	Cible	Type de défaillance (5 classes)

IV. Méthodologie

IV.1 Pré-traitement

Un encodage One-Hot a été appliqué aux variables catégorielles (*company_size*, *industry_sector*, *control_area*). La variable cible a été encodée avec *LabelEncoder*. Les variables numériques continues (*risk_score*, *num_findings*, *remediation_days*) ont été standardisées avec *StandardScaler*. Le dataset a été divisé en 80 % entraînement et 20 % test, avec un split stratifié afin de conserver les proportions de chaque classe.

IV.2 Algorithmes testés

Trois modèles de classification ont été comparés dans le cadre de ce projet :

- **Régression logistique** : modèle de référence, simple et interprétable.
- **Random Forest** : modèle d'ensemble robuste, sélectionné comme modèle principal.
- **K-Nearest Neighbors (KNN)** : modèle basé sur la similarité entre observations.

IV.3 Validation et optimisation

Une validation croisée à 5 blocs (*5-fold cross-validation*) a été appliquée sur l'ensemble d'entraînement afin d'obtenir une estimation stable des performances. Le **Random Forest** ayant obtenu les meilleures performances en validation croisée, ses hyperparamètres (*n_estimators*, *max_depth*, *min_samples_split*) ont ensuite été optimisés via *GridSearchCV*.

V. Résultats

V.1 Analyse exploratoire (EDA)

Le graphique ci-dessous illustre la répartition des 2 000 observations entre les cinq types de défaillances. *Control Deficiency* constitue la classe majoritaire (~36 %), tandis que *Fraud Risk* est la plus rare (~7 %), proportions cohérentes avec les statistiques observées dans les rapports PCAOB réels.




Figure 1 — Répartition des types de défaillances de contrôle interne

Les boxplots du *risk_score* confirment une hiérarchie nette entre les classes. *Fraud Risk* et *Material Weakness* présentent les scores les plus élevés (médiane respective d'environ 88 et 82), tandis que *Control Deficiency* affiche les valeurs les plus basses (médiane ~42). Cette séparation constitue un signal discriminant fort pour les modèles de classification.




Figure 2 — Distribution du Risk Score par type de défaillance

La heatmap de corrélation révèle une corrélation modérée à forte entre *num_findings*, *remediation_days* et *risk_score* (coefficients compris entre 0.64 et 0.76) : plus les constats sont nombreux, plus la remédiation est longue et plus le risque est élevé. La variable *prior_deficiency* présente une corrélation faible avec les autres (0.29–0.31), confirmant son apport indépendant et complémentaire au modèle.




Figure 3 — Matrice de corrélation des variables numériques

V.2 Performances des modèles

Le tableau suivant présente les résultats de la validation croisée (5-fold) pour les trois modèles testés :

Modèle	Accuracy CV (5-fold)	Écart-type
Logistic Regression	76,38 %	± 1,02 %
Random Forest	76,63 %	± 1,65 %
KNN	69,37 %	± 2,14 %

La **Random Forest** obtient la meilleure accuracy en validation croisée (76,63 %). Après optimisation par *GridSearchCV*, les meilleurs hyperparamètres retenus sont *max_depth=10*, *min_samples_split=5* et *n_estimators=200*, avec une accuracy de **74 %** sur le jeu de test.

Le tableau ci-dessous présente le détail des performances par classe sur le jeu de test :

Classe	Précision	Rappel	F1-score	Support
Compliance Violation	0.42	0.22	0.29	68
Control Deficiency	0.85	0.92	0.88	145
Fraud Risk	0.82	0.56	0.67	25
Material Weakness	0.83	0.89	0.86	64
Significant Deficiency	0.63	0.78	0.70	98
Moyenne macro	0.71	0.67	0.68	400

La matrice de confusion ci-dessous illustre ces résultats : *Control Deficiency* et *Material Weakness* sont très bien classifiées (134/145 et 57/64 cas correctement prédits). En revanche, *Compliance Violation* est la classe la plus difficile à identifier, 36 de ses 68 cas étant confondus avec *Significant Deficiency*, deux classes proches par nature.




Figure 4 — Matrice de confusion du modèle Random Forest

La courbe ROC présente une **AUC de 0,84** pour la classe *Material Weakness* contre les autres (approche One-vs-Rest). Le modèle se situe nettement au-dessus de la diagonale en pointillés qui représente un classifieur aléatoire, confirmant sa bonne capacité de discrimination.




Figure 5 — Courbe ROC du modèle Random Forest (AUC = 0,84)

VI. Conclusion

Ce projet a permis de démontrer la faisabilité et la pertinence de l'application du machine learning à la classification des défaillances de contrôle interne dans un contexte SOX. Parmi les trois modèles testés, la **Random Forest** offre les meilleures performances (74 % d'accuracy sur le jeu de test, AUC de 0,84) et constitue le choix le plus adapté pour cette tâche de classification multiclasse.

L'analyse exploratoire a mis en évidence que le *risk_score*, le *num_findings* et la variable *prior_deficiency* sont les variables les plus discriminantes, ce qui est cohérent avec la logique métier de l'audit interne. Les classes *Control Deficiency* et *Material Weakness* sont bien détectées, tandis que *Compliance Violation* reste la plus difficile à classifier en raison de sa proximité sémantique avec *Significant Deficiency*.

Les principales limites de ce travail résident dans l'utilisation d'un dataset synthétique et dans le déséquilibre entre les classes (*Fraud Risk* et *Compliance Violation* sous-représentés). Des pistes d'amélioration incluent la validation sur des données PCAOB réelles, l'application de techniques de rééquilibrage (SMOTE), et l'intégration du traitement automatique du langage (NLP) pour exploiter les textes des rapports d'audit.